

**Informe**  
**Análisis de Riesgo de Crédito**  
**(PCA, Clustering y Predicción de Incumplimiento)**

Dataset: Credit Risk Dataset (Kaggle)

<https://www.kaggle.com/datasets/daniellopez01/credit-risk>

*Machine Learning en Finanzas*

*Paula Pirela*

*Jaber Andrés Olarte*

*Juan Manuel Peña*

## 1. Introducción al problema y contexto

La evaluación del riesgo de crédito busca estimar la probabilidad de que un solicitante incumpla con sus obligaciones. Este problema es relevante para entidades y empresas que otorgan financiación, ya que una mala estimación del riesgo impacta la rentabilidad, la liquidez y el nivel de pérdidas esperadas.

En este trabajo se aborda el riesgo de crédito mediante dos enfoques complementarios:

- Segmentación de clientes con perfiles similares de riesgo
- Predicción de incumplimiento (default) con modelos de aprendizaje automático.


El objetivo es construir un pipeline reproducible que permita identificar grupos con distintos niveles de riesgo y evaluar modelos para clasificar clientes con y sin incumplimiento.

## 2. Descripción de datos y metodología

### 2.1 Descripción de los datos

El dataset incluye variables financieras y demográficas del solicitante (por ejemplo: monto del crédito, duración del préstamo, edad, historia crediticia, balance de cuenta, entre otras) y una variable objetivo:

- default: indica si el cliente incumple ("yes") o no incumple ("no").



Antes del modelado, se aplicó un tratamiento básico para asegurar consistencia en el pipeline.

## Valores faltantes

Se aplicó `dropna()` para eliminar filas con valores faltantes. Esto evita errores en el preprocesamiento y mantiene coherencia en la comparación de modelos.

```
Filas antes: 1000 | después de dropna: 1000 | eliminadas: 0
Conteo:
default
0      700
1      300
Name: count, dtype: int64
```

## Desbalance de clases

Se verificó la proporción de la clase positiva (`default = yes`) respecto a la negativa (`default = no`). El nivel de desbalance influye en la selección de métricas (por ejemplo PR AUC) y en la conveniencia de técnicas como SMOTE.

## 2.2 Metodología (pipeline)

La metodología se dividió en cuatro etapas principales:



- Preprocesamiento (One-Hot + escalado).
- Reducción de dimensionalidad con PCA.
- Segmentación con K-Means.
- Predicción de incumplimiento con modelos supervisados.

### Preprocesamiento

Se separaron variables numéricas y categóricas. Las numéricas se estandarizaron con `StandardScaler` y las categóricas se codificaron con `OneHotEncoder`. Esto permitió representar el dataset en un espacio numérico apto para PCA, clustering y modelos supervisados.


### PCA (reducción de dimensionalidad)


Se aplicó PCA para reducir dimensionalidad preservando aproximadamente el 95% de la varianza explicada. Además, se generaron visualizaciones para inspeccionar la varianza acumulada y una proyección 2D del espacio de componentes.



## Clustering (K-Means sobre PCA)

Se aplicó K-Means sobre los componentes principales (PCA al 95% de varianza) para segmentar clientes. Para seleccionar el número de clusters  $k$  se evaluaron el método del codo (inercia) y el silhouette score.





|         | n   | default_rate | avg_amount  | avg_duration | avg_age   | avg_percent_income |
|---------|-----|--------------|-------------|--------------|-----------|--------------------|
| cluster |     |              |             |              |           |                    |
| 0       | 119 | 0.521008     | 9060.924370 | 40.747899    | 35.495798 | 2.504202           |
| 1       | 185 | 0.318919     | 2508.421622 | 19.691892    | 29.848649 | 2.983784           |
| 2       | 145 | 0.296552     | 2953.951724 | 18.772414    | 38.744828 | 2.806897           |
| 4       | 225 | 0.293333     | 2158.426667 | 16.391111    | 30.031111 | 3.048889           |
| 3       | 202 | 0.237624     | 2644.995050 | 19.178218    | 32.183168 | 3.049505           |
| 5       | 124 | 0.177419     | 2263.645161 | 17.153226    | 55.838710 | 3.338710           |

## Modelos de predicción y evaluación

Se entrenaron y compararon modelos para predecir default: Logistic Regression, MLP (red neuronal) y RandomForest (árboles) como benchmark. Adicionalmente, se evaluó el uso de SMOTE aplicado únicamente al conjunto de entrenamiento para mitigar desbalance, comparando resultados con y sin SMOTE.

Las métricas reportadas fueron Accuracy (ACC), ROC AUC y PR AUC (Average Precision). PR AUC es especialmente útil cuando existe desbalance, ya que resume el trade-off entre precision y recall para la clase positiva.

## 3. Resultados con visualizaciones

### 3.1 Segmentación (K-Means)

Los resultados de codo y silhouette permitieron definir un valor de k para la segmentación. Posteriormente, el perfilado mostró diferencias en tasas de incumplimiento entre clusters, lo cual sugiere que la segmentación captura patrones relevantes del riesgo.

### 3.2 Predicción de incumplimiento (modelos supervisados)

Se compararon los modelos en un conjunto de prueba (test) usando ACC, ROC AUC y PR AUC. Además, se generaron curvas ROC, curvas Precision-Recall y matrices de confusión.

|   | model                                | ACC   | ROC_AUC  | PR_AUC   |
|---|--------------------------------------|-------|----------|----------|
| 2 | MLP PCA (sin SMOTE)                  | 0.750 | 0.774048 | 0.619806 |
| 0 | LogReg PCA (sin SMOTE, class_weight) | 0.710 | 0.787738 | 0.616056 |
| 1 | LogReg PCA (con SMOTE)               | 0.690 | 0.788571 | 0.607615 |
| 4 | RandomForest PCA (sin SMOTE)         | 0.750 | 0.752738 | 0.603496 |
| 5 | RandomForest PCA (con SMOTE)         | 0.675 | 0.740476 | 0.594788 |
| 3 | MLP PCA (con SMOTE)                  | 0.705 | 0.769048 | 0.590896 |

## 4. Discusión de hallazgos y limitaciones

### 4.1 Discusión de hallazgos

El enfoque PCA + K-Means permitió segmentar clientes y observar diferencias en la tasa de incumplimiento entre clusters, lo cual puede apoyar acciones de perfilamiento de riesgo (por ejemplo, políticas diferenciadas por segmento).

En el componente supervisado, los modelos mostraron un desempeño moderado, con métricas ROC AUC y PR AUC consistentes con el nivel de complejidad del dataset. En los experimentos realizados, SMOTE no produjo mejoras en PR AUC, por lo que se recomienda priorizar la versión sin SMOTE para el modelo final.

### 4.2 Limitaciones

- Generalización: el dataset puede no representar completamente poblaciones reales o actuales.
- Hiperparámetros: los modelos se entrenaron con configuraciones base; una búsqueda sistemática (Grid/Random Search) podría mejorar resultados.
- Métrica operativa: en escenarios reales puede ser más relevante optimizar recall de la clase positiva o un costo financiero asociado a errores.
- Interpretabilidad: modelos como MLP o RandomForest pueden requerir técnicas adicionales para explicar resultados (por ejemplo, importancia de variables).

## 5. Conclusiones

Se implementó un pipeline que integra preprocesamiento, PCA, segmentación (K-Means) y modelos supervisados para predicción de incumplimiento. Los resultados evidencian que la segmentación puede producir grupos con perfiles de riesgo diferenciados y que los modelos supervisados alcanzan un desempeño competitivo bajo métricas ROC AUC y PR AUC. Como trabajo futuro se recomienda afinar hiperparámetros, ajustar umbrales de decisión según el objetivo operativo y profundizar en interpretabilidad.

## 6. Referencias

- Kaggle - Credit Risk Dataset:  
<https://www.kaggle.com/datasets/daniellopez01/credit-risk>